Étude et évaluation d'une approche de fusion probabiliste pondérée pour la classification des réponses humaines et générées par l'intelligence artificielle ⋆

Chahde EL MOHTADI[a], Intissar SAOUDI[a]

[a]*Département Mathématiques et Informatique – DUT-IDRS-S3, École Supérieure de Technologie, Kénitra, 14000, Université Ibn Tofaïl, Maroc*

ARTICLE INFO

Keywords:
Détection de textes générés par l'intelligence artificielle
Classification binaire
TF-IDF
Caractéristiques stylistiques
Fusion probabiliste pondérée
Régression logistique

Résumé

L'utilisation croissante des outils d'intelligence artificielle a rendu la distinction entre les textes rédigés par des humains et ceux générés par l'IA particulièrement importante. Cette étude porte sur la classification des réponses humaines et des réponses générées par l'intelligence artificielle à partir de caractéristiques lexicales et stylistiques.

Les expériences sont réalisées sur un jeu de données consacré aux statistiques appliquées, contenant initialement 4 231 réponses. Après prétraitement, 4 163 observations sont conservées. Afin de réduire les risques de fuite de données, les réponses sont réparties en ensembles d'entraînement, de validation et de test selon leurs questions.

Trois approches de classification sont évaluées : TF-IDF associé à la régression logistique, les caractéristiques stylistiques associées à la régression logistique et un modèle hybride combinant les deux types de caractéristiques. En complément, une approche de fusion probabiliste pondérée est étudiée en combinant les prédictions des modèles TF-IDF et stylistique.

Les résultats expérimentaux montrent que le modèle TF-IDF obtient les meilleures performances globales sur l'ensemble de test, avec une exactitude de 82,17 % et un score F1 de 81,96 %. La fusion probabiliste pondérée atteint une exactitude de 82,05 %, un score F1 de 81,77 % et la meilleure précision parmi les approches évaluées, avec 85,68 %. Ces résultats montrent que les caractéristiques lexicales sont particulièrement efficaces sur ce jeu de données, tandis que la fusion pondérée présente un compromis différent entre précision et rappel.

Points forts

- Évaluation des caractéristiques lexicales et stylistiques pour distinguer les réponses humaines des réponses générées par l'IA.
- Utilisation d'une séparation des données par question afin de réduire les risques de fuite de données.
- Comparaison de trois modèles de classification et d'une approche de fusion probabiliste pondérée.
- Le modèle TF-IDF obtient le meilleur score F1 sur l'ensemble de test, avec 81,96 %.
- La fusion probabiliste pondérée atteint la meilleure précision, avec 85,68 %.

1. Introduction

La génération automatique de textes par les systèmes d'intelligence artificielle a connu un développement important ces dernières années. Les modèles de langage modernes sont capables de produire des réponses cohérentes, structurées et proches de celles rédigées par des êtres humains.

Cette évolution soulève plusieurs difficultés, notamment la distinction entre les textes générés par une intelligence artificielle et ceux rédigés par des humains. Cette distinction peut être importante dans plusieurs domaines, tels que l'éducation, l'évaluation académique et la vérification de l'origine des contenus textuels.

Cependant, la détection automatique de textes générés par l'IA reste un problème complexe. Les caractéristiques lexicales et stylistiques des textes peuvent varier selon le domaine, la longueur des réponses et le modèle utilisé pour leur génération.

⋆ Travaux pratiques – Module Machine Learning, DUT Informatique S3. Année universitaire 2026–2027.

Dans ce contexte, notre travail porte sur la classification des réponses humaines et des réponses générées par l'intelligence artificielle. Nous étudions plusieurs approches de Machine Learning, notamment TF-IDF associé à la régression logistique, les caractéristiques stylistiques et une approche hybride basée sur la combinaison de ces informations.

Enfin, nous proposons une stratégie de fusion pondérée des probabilités de deux modèles afin d'étudier l'intérêt de leur combinaison pour cette tâche de classification.

Les principales contributions de ce travail sont les suivantes :

1. Prétraitement du jeu de données et séparation des données en groupes selon les questions afin de réduire les risques de fuite de données.
2. Évaluation de trois approches : TF-IDF avec régression logistique, caractéristiques stylistiques avec régression logistique et modèle hybride.
3. Étude d'une méthode de fusion probabiliste pondérée combinant les prédictions des modèles TF-IDF et stylistique.
4. Comparaison expérimentale des approches à l'aide des métriques d'exactitude, de précision, de rappel et de score F1.

2. Positionnement et travaux existants

La détection des textes générés par l'intelligence artificielle constitue un domaine de recherche qui regroupe plusieurs approches, notamment les méthodes statistiques, l'analyse linguistique et les techniques de classification automatique.

Gehrmann et al. (1) ont proposé GLTR, un outil fondé sur des méthodes statistiques permettant d'analyser les caractéristiques des textes générés par les modèles de langage. Cette approche montre l'intérêt des informations statistiques pour distinguer les textes humains des textes générés.

Mitchell et al. (2) ont proposé DetectGPT, une méthode de détection basée sur la courbure des probabilités des modèles de langage. Contrairement aux méthodes classiques de classification supervisée, cette approche utilise les probabilités du modèle générateur pour identifier les textes susceptibles d'être générés automatiquement.

Par ailleurs, Wu et al. (3) présentent une synthèse des principales méthodes de détection des textes générés par les grands modèles de langage. Leur étude met notamment en évidence les difficultés liées à la généralisation des détecteurs entre différents domaines et modèles.

Dans ce contexte, notre travail adopte une approche expérimentale basée sur des méthodes classiques de Machine Learning. Nous comparons les représentations lexicales TF-IDF, les caractéristiques stylistiques et leur combinaison dans un modèle hybride. Nous étudions également une fusion probabiliste pondérée des prédictions des modèles TF-IDF et stylistique.

Contrairement aux approches précédentes qui reposent sur des analyses statistiques spécifiques ou sur les probabilités de modèles de langage, notre étude évalue des classificateurs supervisés sur un jeu de données consacré aux réponses en statistiques appliquées. L'objectif est de mesurer l'apport respectif des informations lexicales et stylistiques, sans supposer que leur combinaison améliore nécessairement les performances globales.

3. Méthodologie proposée

3.1. Notations et formulation mathématique

Soit $D = \{(x_i, y_i)\}_{i=1}^{N}$ notre jeu de données, où x_i représente une réponse textuelle et $y_i \in \{0, 1\}$ représente sa classe. La classe 0 correspond aux réponses humaines, tandis que la classe 1 correspond aux réponses générées par l'intelligence artificielle.

Notre approche repose sur deux modèles de classification : un modèle basé sur TF-IDF et un modèle utilisant des caractéristiques stylistiques. Les deux modèles utilisent la régression logistique et produisent une probabilité d'appartenance à la classe IA.

La fusion probabiliste pondérée est définie par :

$$P_{\text{final}}(y = 1 \mid x) = \alpha P_{\text{TF-IDF}}(y = 1 \mid x) + (1 - \alpha) P_{\text{Style}}(y = 1 \mid x) \tag{1}$$

où $\alpha \in [0, 1]$ représente le poids attribué au modèle TF-IDF, tandis que $(1 - \alpha)$ représente le poids du modèle stylistique.

Le paramètre α est sélectionné à partir de l'ensemble de validation. Nous avons testé plusieurs valeurs entre 0 et 1 avec un pas de 0,1. La valeur retenue est $\alpha = 0{,}9$.

La prédiction finale est obtenue en appliquant un seuil de décision égal à 0,5 :

$$\hat{y} = \begin{cases} 1 & \text{si } P_{\text{final}}(y = 1 \mid x) \geq 0{,}5 \\ 0 & \text{sinon} \end{cases} \tag{2}$$

3.2. Procédure expérimentale

La procédure suivie pour évaluer notre approche est organisée selon les étapes suivantes :

1. Prétraiter le jeu de données et supprimer les observations incomplètes, les doublons exacts et les conflits d'étiquettes.
2. Diviser les données en ensembles d'entraînement, de validation et de test en regroupant les réponses selon leurs questions.
3. Entraîner séparément le modèle TF-IDF et le modèle basé sur les caractéristiques stylistiques.
4. Évaluer les deux modèles sur l'ensemble de validation et sélectionner le poids α donnant le meilleur score F1 pour la fusion.
5. Réentraîner les modèles sur les ensembles d'entraînement et de validation combinés.
6. Appliquer la fusion avec le poids sélectionné et évaluer les performances finales sur l'ensemble de test, utilisé uniquement pour l'évaluation.

4. Implémentation et protocole expérimental

4.1. Jeu de données et prétraitement

Dans cette étude, nous utilisons le jeu de données intitulé *An Applied Statistics dataset for human vs AI-generated answer classification*, publié en 2024 et disponible sur la plateforme Mendeley Data.

Le jeu de données initial contient 4 231 réponses associées à des questions du domaine des statistiques appliquées. Chaque observation comprend une question, une réponse et une étiquette indiquant l'origine de la réponse : humaine (0) ou générée par l'intelligence artificielle (1).

Une étape de prétraitement a été réalisée afin d'améliorer la qualité des données. Elle comprend la suppression des réponses manquantes, des doublons exacts et des paires question-réponse présentant des étiquettes contradictoires. Après cette étape, 4 163 observations sont conservées, réparties en 2 026 réponses humaines et 2 137 réponses générées par l'IA.

La séparation des données est réalisée en regroupant les observations selon leurs questions, à l'aide de la méthode StratifiedGroupKFold. Cette stratégie permet de limiter la fuite de données liée à la présence de réponses associées à une même question dans plusieurs ensembles.

Les données sont réparties en trois ensembles : entraînement (2 657 observations), validation (659 observations) et test (847 observations). Aucune question n'est partagée entre ces trois ensembles. Afin d'éviter toute fuite d'information, les transformations sont d'abord ajustées sur les données d'entraînement, puis appliquées aux données de validation pour la sélection des hyperparamètres. Après cette étape, les modèles et les transformations sont réajustés sur les ensembles d'entraînement et de validation combinés avant l'évaluation finale sur l'ensemble de test.

4.2. Environnement technique

L'implémentation expérimentale repose sur l'environnement technique suivant :

- Langage de programmation : Python 3.14.7.
- Bibliothèques : Pandas, NumPy et Scikit-learn.
- Modèles : régression logistique et vectorisation TF-IDF.
- Prétraitement des caractéristiques stylistiques : StandardScaler.

- Reproductibilité : `random_state` fixé à 42.

Les expériences ont été réalisées dans un environnement Python sous Windows.

4.3. Métriques d'évaluation

Les performances des modèles sont évaluées à l'aide de quatre métriques classiques de classification : l'exactitude, la précision, le rappel et le score F1.

Dans cette étude, la classe positive correspond aux réponses générées par l'intelligence artificielle (classe 1). Les métriques de précision, de rappel et de score F1 sont calculées par rapport à cette classe.

$$\text{Exactitude} = \frac{TP + TN}{TP + TN + FP + FN} \tag{3}$$

$$\text{Précision} = \frac{TP}{TP + FP} \tag{4}$$

$$\text{Rappel} = \frac{TP}{TP + FN} \tag{5}$$

$$F1 = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}} \tag{6}$$

où TP représente les vrais positifs, TN les vrais négatifs, FP les faux positifs et FN les faux négatifs.

5. Résultats et analyse

Les performances des quatre approches ont été évaluées sur l'ensemble de test composé de 847 observations. Les résultats obtenus sont présentés dans le tableau suivant.

Tableau 1
Comparaison des performances des modèles sur l'ensemble de test.

Méthode	Exactitude (%)	Précision (%)	Rappel (%)	Score F1 (%)
TF-IDF + Régression logistique	82,17	85,54	78,67	81,96
Caractéristiques stylistiques + Régression logistique	73,20	75,30	71,33	73,26
Modèle hybride TF-IDF + caractéristiques stylistiques	80,28	83,37	77,06	80,10
Fusion pondérée ($\alpha = 0{,}9$)	82,05	85,68	78,21	81,77

Les résultats montrent que le modèle TF-IDF associé à la régression logistique obtient les meilleures performances globales, avec une exactitude de 82,17 % et un score F1 de 81,96 %.

Le modèle basé uniquement sur les caractéristiques stylistiques obtient des performances plus faibles, avec un score F1 de 73,26 %. Le modèle hybride améliore ces résultats, mais reste inférieur au modèle TF-IDF.

La fusion probabiliste pondérée, avec $\alpha = 0{,}9$, atteint une précision de 85,68 %, la plus élevée parmi les quatre approches. Cependant, son score F1 (81,77 %) reste légèrement inférieur à celui du modèle TF-IDF seul.

Ces résultats montrent que la fusion pondérée présente un intérêt en termes de précision, mais qu'elle n'améliore pas les performances globales du meilleur modèle de référence sur cet ensemble de test.

6. Discussion

Les résultats obtenus montrent que les performances dépendent du type de caractéristiques utilisées. Le modèle TF-IDF obtient le meilleur score F1 (81,96 %) et la meilleure exactitude (82,17 %), ce qui indique que les informations lexicales sont particulièrement discriminantes dans ce jeu de données.

Le modèle basé uniquement sur les caractéristiques stylistiques obtient des résultats inférieurs, avec un score F1 de 73,26 %. Le modèle hybride atteint un score F1 de 80,10 %, ce qui montre que l'ajout de caractéristiques stylistiques n'améliore pas systématiquement les performances par rapport à TF-IDF seul.

La fusion probabiliste pondérée, avec $\alpha = 0{,}9$, obtient la meilleure précision (85,68 %). Cependant, son score F1 (81,77 %) reste légèrement inférieur à celui du modèle TF-IDF. La combinaison des probabilités ne garantit donc pas une amélioration globale des performances.

Cette étude présente plusieurs limites. Premièrement, l'évaluation repose sur un seul jeu de données spécialisé dans les statistiques appliquées, ce qui limite la généralisation à d'autres domaines, langues et modèles génératifs. Deuxièmement, malgré la séparation des données par question, des similarités sémantiques ou des quasi-doublons peuvent subsister entre les ensembles. Enfin, les résultats sont obtenus sur un seul découpage fixe et ne représentent pas une moyenne sur plusieurs répétitions indépendantes.

Comme perspectives, il serait intéressant d'évaluer les modèles sur des jeux de données plus diversifiés, notamment en français et en arabe, de tester d'autres algorithmes de classification et d'étudier la stabilité du poids α.

7. Conclusion

Ce travail a étudié la classification des réponses humaines et des réponses générées par l'intelligence artificielle à l'aide de caractéristiques lexicales et stylistiques. Quatre approches ont été comparées : TF-IDF avec régression logistique, caractéristiques stylistiques avec régression logistique, modèle hybride et fusion probabiliste pondérée.

Les résultats obtenus sur l'ensemble de test montrent que le modèle TF-IDF présente les meilleures performances globales, avec une exactitude de 82,17 % et un score F1 de 81,96 %. La fusion pondérée, avec $\alpha = 0{,}9$, obtient la meilleure précision (85,68 %), mais n'améliore pas le score F1 global.

Ainsi, la fusion probabiliste constitue une approche intéressante, mais elle ne surpasse pas le modèle TF-IDF seul dans cette expérimentation.

Une perspective importante consiste à tester ces approches sur des corpus plus diversifiés, couvrant plusieurs domaines et langues, afin d'évaluer leur capacité de généralisation face à différents modèles de génération de texte.

Remerciements

Nous tenons à remercier notre encadrante, Pr. Chaimae Boulahia, pour son accompagnement, ses conseils et ses orientations tout au long de ce travail pratique. Nous la remercions également pour les connaissances transmises dans le cadre du module Machine Learning.

Références

[1] Gehrmann, S., Strobelt, H., and Rush, A. (2019). GLTR: Statistical Detection and Visualization of Generated Text. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics: System Demonstrations, 111–116.

[2] Mitchell, E., Lee, Y., Khazatsky, A., Manning, C. D., and Finn, C. (2023). DetectGPT: Zero-Shot Machine-Generated Text Detection using Probability Curvature. Proceedings of the 40th International Conference on Machine Learning, 202, 24950–24962.

[3] Wu, J., Yang, S., Zhan, R., Yuan, Y., Chao, L. S., and Wong, D. F. (2025). A Survey on LLM-Generated Text Detection: Necessity, Methods, and Future Directions. Computational Linguistics, 51(1), 275–338.